

1) Analysis

August 23, 2023

1 1) Preparación previa

Carga de librerías

```
[1]: import pandas as pd
import numpy as np

import matplotlib.pyplot as plt
import matplotlib as mpl
%matplotlib inline
import seaborn as sns

from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score, silhouette_samples

import warnings
warnings.filterwarnings('ignore')
```

Lectura del dataset Se decidió utilizar unos datos históricos de criptomonedas. El tema nos interesó no solo por estar más vigente que nunca, sino porque nos resultó excelente para explayar diversas herramientas aprendidas en el curso.

```
[2]: df_aave = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Aave.csv')
df_binancecoin = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_BinanceCoin.csv')
df_bitcoin = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Bitcoin.csv')
df_cardano = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Cardano.csv')
df_chainlink = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_ChainLink.csv')
```

```

df_cosmos = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Cosmos.csv')
df_cryptocomcoin = pd.read_csv('https://raw.githubusercontent.com/
↳Agustin-Bulzomi/Projects/main/Programming/Digital%20House%20(Python)/
↳Support%20Files/Final%20Project/coin_CryptocomCoin.csv')
df_dogecoin = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Dogecoin.csv')
df_eos = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_EOS.csv')
df_ethereum = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Ethereum.csv')
df_iota = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Iota.csv')
df_litecoin = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Litecoin.csv')
df_monero = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Monero.csv')
df_nem = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_NEM.csv')
df_polkadot = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Polkadot.csv')
df_solana = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Solana.csv')
df_stellar = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Stellar.csv')
df_tether = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Tether.csv')
df_tron = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Trone.csv')
df_uniswap = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_Uniswap.csv')

```

```
df_usdcoin = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_USDCoin.csv')
df_wrappedbitcoin = pd.read_csv('https://raw.githubusercontent.com/
↳Agustin-Bulzomi/Projects/main/Programming/Digital%20House%20(Python)/
↳Support%20Files/Final%20Project/coin_WrappedBitcoin.csv')
df_xrp = pd.read_csv('https://raw.githubusercontent.com/Agustin-Bulzomi/
↳Projects/main/Programming/Digital%20House%20(Python)/Support%20Files/
↳Final%20Project/coin_XRP.csv')
```

Vista general Se corren varias funciones para obtener un resumen general de los datasets, eligiendo uno (bitcoin) como ejemplo para analizar la estructura e información de todos, ya que son iguales

```
[3]: df_bitcoin
```

```
[3]:
```

	SNo	Name	Symbol	Date	High	Low \
0	1	Bitcoin	BTC	2013-04-29	147.488007	134.000000
1	2	Bitcoin	BTC	2013-04-30	146.929993	134.050003
2	3	Bitcoin	BTC	2013-05-01	139.889999	107.720001
3	4	Bitcoin	BTC	2013-05-02	125.599998	92.281898
4	5	Bitcoin	BTC	2013-05-03	108.127998	79.099998
...
2857	2858	Bitcoin	BTC	2021-02-23	54204.929760	45290.590270
2858	2859	Bitcoin	BTC	2021-02-24	51290.136690	47213.498160
2859	2860	Bitcoin	BTC	2021-02-25	51948.966980	47093.853020
2860	2861	Bitcoin	BTC	2021-02-26	48370.785260	44454.842110
2861	2862	Bitcoin	BTC	2021-02-27	48253.270100	45269.025770

	Open	Close	Volume	Marketcap
0	134.444000	144.539993	0.000000e+00	1.603769e+09
1	144.000000	139.000000	0.000000e+00	1.542813e+09
2	139.000000	116.989998	0.000000e+00	1.298955e+09
3	116.379997	105.209999	0.000000e+00	1.168517e+09
4	106.250000	97.750000	0.000000e+00	1.085995e+09
...
2857	54204.929760	48824.426870	1.061020e+11	9.099260e+11
2858	48835.087660	49705.333320	6.369552e+10	9.263930e+11
2859	49709.082420	47093.853020	5.450657e+10	8.777660e+11
2860	47180.464050	46339.760080	3.509680e+11	8.637520e+11
2861	46344.772240	46188.451280	4.591095e+10	8.609780e+11

```
[2862 rows x 10 columns]
```

Se observan los tipos de datos que conforman el dataset

```
[4]: df_bitcoin.dtypes
```

```
[4]: SNo          int64
      Name        object
      Symbol      object
      Date        object
      High        float64
      Low         float64
      Open        float64
      Close       float64
      Volume      float64
      Marketcap   float64
      dtype: object
```

Se chequea la existencia de valores nulos

```
[5]: df_bitcoin.isna().sum()
```

```
[5]: SNo          0
      Name        0
      Symbol      0
      Date        0
      High        0
      Low         0
      Open        0
      Close       0
      Volume      0
      Marketcap   0
      dtype: int64
```

Unificación de los datasets Se utiliza un for loop para crear un dataframe que preserve los datos de cada dataset que nos conciernen

```
[6]: # Se crea una tupla para la iteración de los datasets en el for loop
lista_cryptos = [df_aave, df_binancecoin, df_bitcoin, df_cardano, df_chainlink,
    ↪df_cosmos, df_cryptocomcoin, df_dogecoin, df_eos, df_ethereum, df_iota,
    ↪df_litecoin, df_monero,
                        df_nem, df_polkadot, df_solana, df_stellar, df_tether,
    ↪df_tron, df_uniswap, df_usdcoin, df_wrappedbitcoin, df_xrp]

# Se crea un dataframe vacío para aplicarle el append al final del loop
cryptos = pd.DataFrame()

# Además de obtener las columnas que importan, se crea la columna "Volatilidad"
for dataframe in lista_cryptos:
    variaciones = dataframe.Close.pct_change()
    volatilidad_diaria = np.sqrt(np.abs(variaciones))
    dataframe["Volatilidad"] = volatilidad_diaria
    df_temp = dataframe[['Date', 'Symbol', 'Close', 'Marketcap', 'Volatilidad']]
    cryptos = cryptos.append(df_temp)
```

```
cryptos.set_index(['Date', 'Symbol'])

# La volatilidad generan NaNs por no poder contrastar los primeros valores
↳ históricos de cada moneda con una fecha anterior sin valores
cryptos = cryptos.replace(np.nan, 0)
cryptos
```

```
[6]:
```

	Date	Symbol	Close	Marketcap	Volatilidad
0	2020-10-05 23:59:59	AAVE	53.219243	8.912813e+07	0.000000
1	2020-10-06 23:59:59	AAVE	42.401599	7.101144e+07	0.450850
2	2020-10-07 23:59:59	AAVE	40.083976	6.713004e+07	0.233792
3	2020-10-08 23:59:59	AAVE	43.764463	2.202651e+08	0.303017
4	2020-10-09 23:59:59	AAVE	46.817744	2.356322e+08	0.264133
...
2759	2021-02-23 23:59:59	XRP	0.473563	2.150165e+10	0.414389
2760	2021-02-24 23:59:59	XRP	0.471832	2.142305e+10	0.060460
2761	2021-02-25 23:59:59	XRP	0.434524	1.972912e+10	0.281195
2762	2021-02-26 23:59:59	XRP	0.427900	1.942839e+10	0.123462
2763	2021-02-27 23:59:59	XRP	0.437809	1.987829e+10	0.152174

[34115 rows x 5 columns]

Tratamiento de la columna Date Se pasa la columna Date al formato datetime. A su vez, se crea la columna Year para análisis anual y se le quita la hora a la columna Date

```
[7]: cryptos['Date'] = pd.to_datetime(cryptos['Date'])
cryptos['Year'] = cryptos['Date'].dt.year
cryptos['Date'] = pd.to_datetime(cryptos['Date']).dt.date
```

```
[8]: cryptos
```

```
[8]:
```

	Date	Symbol	Close	Marketcap	Volatilidad	Year
0	2020-10-05	AAVE	53.219243	8.912813e+07	0.000000	2020
1	2020-10-06	AAVE	42.401599	7.101144e+07	0.450850	2020
2	2020-10-07	AAVE	40.083976	6.713004e+07	0.233792	2020
3	2020-10-08	AAVE	43.764463	2.202651e+08	0.303017	2020
4	2020-10-09	AAVE	46.817744	2.356322e+08	0.264133	2020
...
2759	2021-02-23	XRP	0.473563	2.150165e+10	0.414389	2021
2760	2021-02-24	XRP	0.471832	2.142305e+10	0.060460	2021
2761	2021-02-25	XRP	0.434524	1.972912e+10	0.281195	2021
2762	2021-02-26	XRP	0.427900	1.942839e+10	0.123462	2021
2763	2021-02-27	XRP	0.437809	1.987829e+10	0.152174	2021

[34115 rows x 6 columns]

2 2) Análisis exploratorio

2.1 Clustering

Introducción Se pretende encontrar puntos en común entre las distintas criptomonedas, tomando como variables el Marketcap y la Volatilidad a lo largo de su historia. Intuitivamente, se puede pensar que las monedas irán cambiando de cluster a lo largo de los años, y las más recientes serán de mayor volatilidad y menor marketcap. Ahí radica la importancia de la variable Year en el análisis que se desarrollará

```
[9]: # Se eligen las variables a analizar y se estandariza
```

```
X = cryptos[['Marketcap', 'Volatilidad']]
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X);
```

La comparación de puntajes en Silhouette score y en Calinski-Harabasz es fundamental previo a la aplicación del modelo de clustering, para definir K en Kmeans

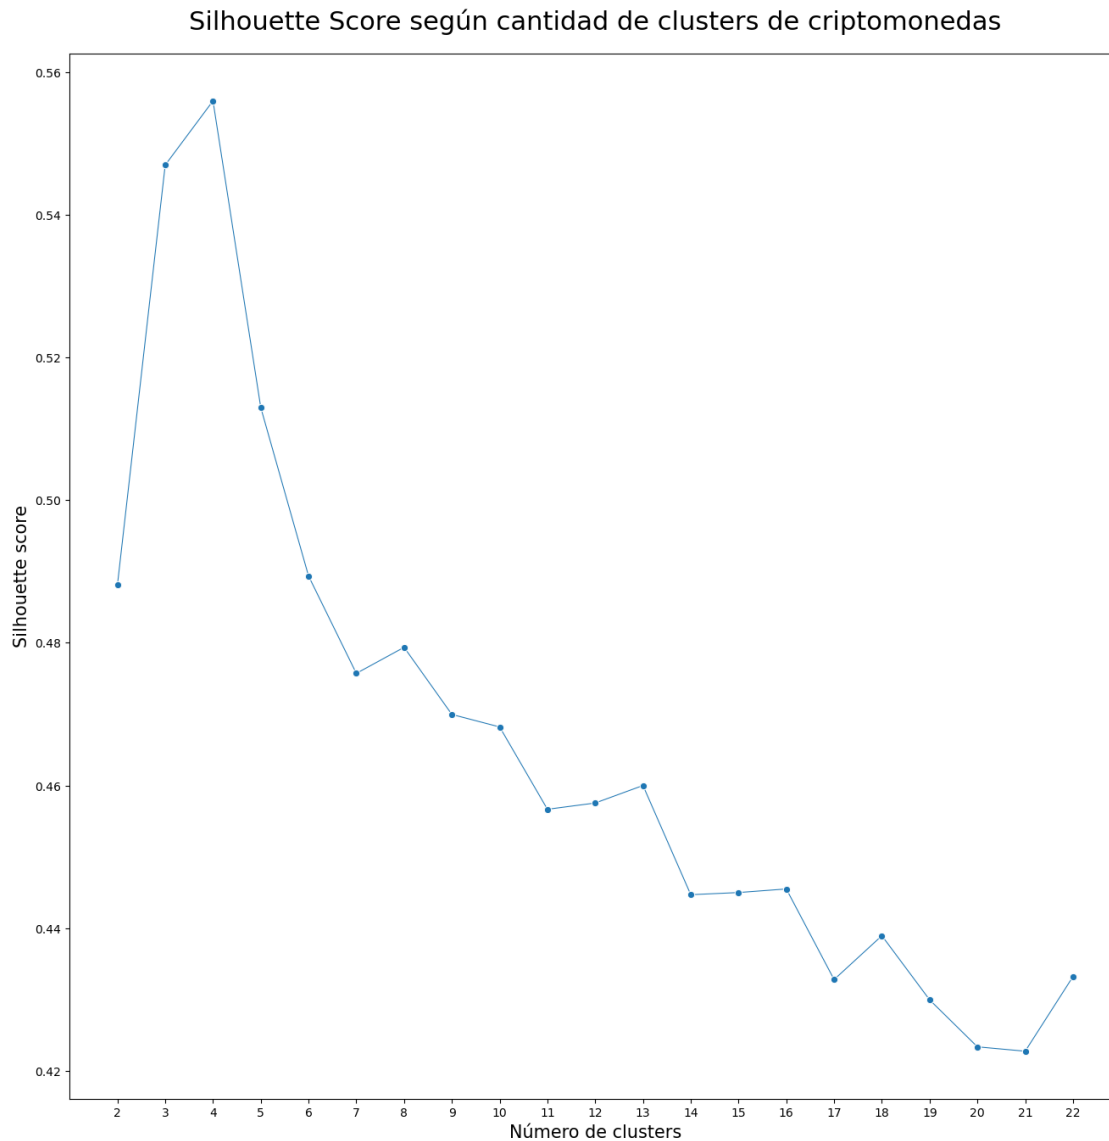
Silhouette Score:

```
[10]: sil=[]
      k_values = range(2,23);

      for k in k_values:
          kmeans = KMeans(n_clusters = k, n_init = 10, random_state = 0)
          kmeans.fit(X_scaled)
          score = silhouette_score(X_scaled, kmeans.labels_)
          sil.append(score)
```

```
[11]: plt.figure(figsize=(16, 16))
      sns.lineplot(x = k_values, y = sil, marker = 'o', size = 25, legend = False);
      plt.ylabel('Silhouette score', fontsize = 15);
      plt.xlabel('Número de clusters', fontsize = 15);
      plt.xticks(np.arange(2, 23, 1))
      plt.title("Silhouette Score según cantidad de clusters de criptomonedas",
                ↪ fontsize = 22, pad = 20);

      plt.savefig('Silhouette Score')
```



```
[12]: print("La cantidad de clusters que optimizan el Silhouette Score es:", np.
      ↪ argmax(sil) + 2) # Se suma 2 al índice que dio el valor máximo pues el
      ↪ mínimo del rango a analizar era 2.
```

La cantidad de clusters que optimizan el Silhouette Score es: 4

KMeans

```
[13]: kmeans = KMeans(n_clusters = 4, n_init=10, random_state = 0)
      kmeans.fit(X_scaled)

      labels = kmeans.labels_
      centroids = kmeans.cluster_centers_
```

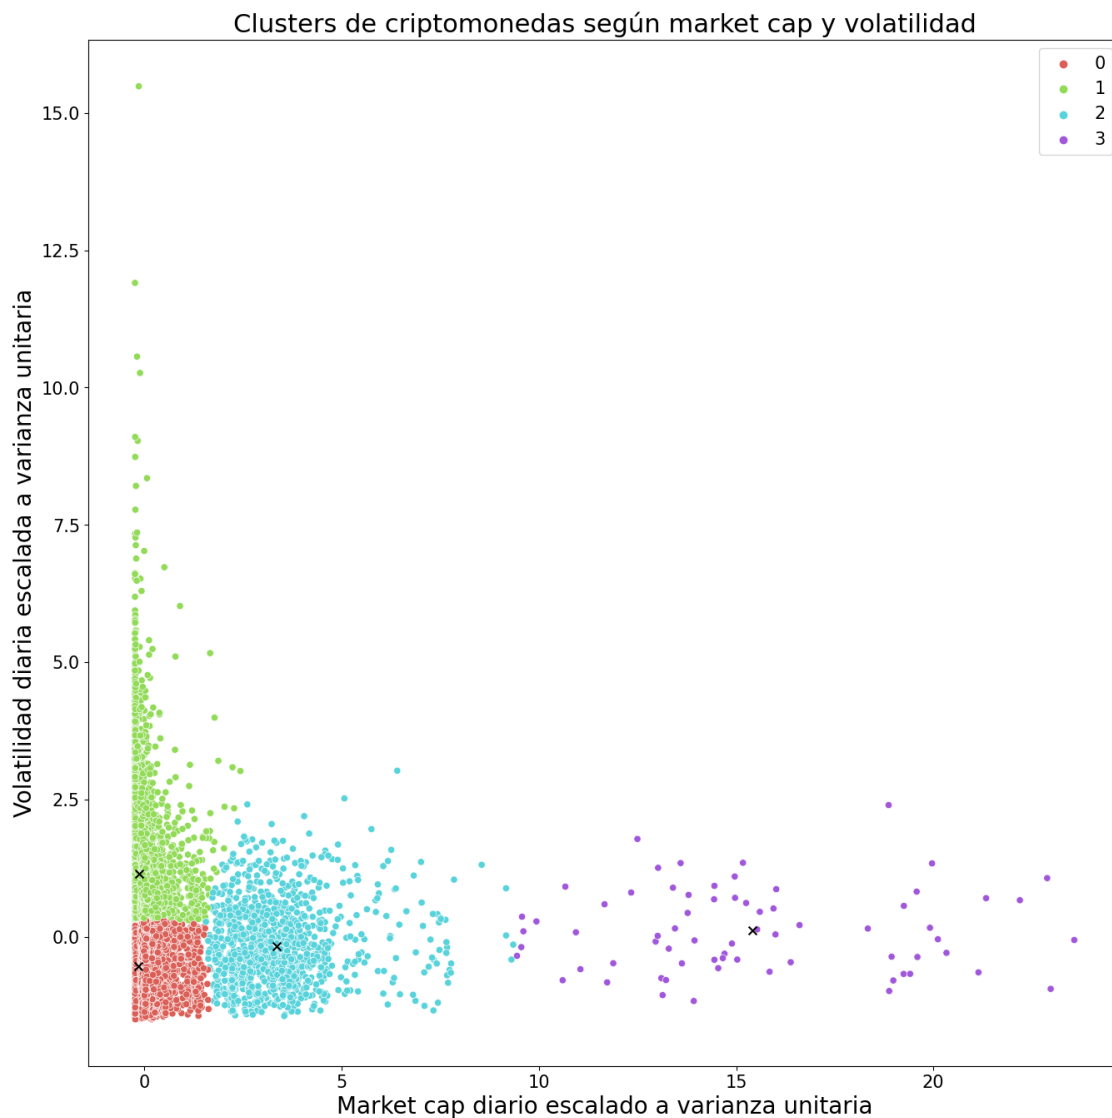
```

color_palette= sns.color_palette("hls", 4)

plt.figure(figsize = (16,16));
sns.scatterplot(x=X_scaled[:,0],y=X_scaled[:,1],hue=labels,legend='full',
               ↪palette= color_palette);
plt.xlabel('Market cap diario escalado a varianza unitaria',fontsize=20);
plt.ylabel('Volatilidad diaria escalada a varianza unitaria',fontsize=20);
plt.xticks(fontsize=15)
plt.yticks(fontsize=15)
plt.scatter(centroids[:,0],centroids[:,1],marker='x',s=50,color='k');
plt.legend(prop={'size': 15})
plt.title("Clusters de criptomonedas según market cap y volatilidad",
        ↪fontsize=22);

plt.savefig("KMeans.png")

```



En el análisis financiero de las criptomonedas, hay una cierta continuidad en el desarrollo de las mismas: si son exitosas van aumentando su market cap y perdiendo volatilidad. En ese sentido, tiene más lógica que el cluster 0 sea el más volátil y de menor marketcap, mientras que el 3 sea de menor volatilidad y mayor marketcap, para así representar de manera ascendente el desarrollo histórico de las criptomonedas. Por lo susodicho, se alterarán los labels de Kmeans: el cluster 3 debería ser el 2 (y viceversa) y el cluster 1 debería ser el 0 (y viceversa) para representar la siguiente lógica:

Cluster 0: baja volatilidad + bajo marketcap

Cluster 1: alta volatilidad + bajo marketcap

Cluster 2: baja volatilidad + mediano marketcap

Cluster 3: baja volatilidad + alto marketcap

```
[14]: X_clustered = kmeans.predict(X_scaled)
cryptos["Cluster_inicial"] = X_clustered
cryptos["Cluster1"] = cryptos["Cluster_inicial"].apply(lambda x : 1 if x == 0
↪else 0)
cryptos["Cluster0"] = cryptos["Cluster_inicial"].apply(lambda x : 0 if x == 1
↪else 0)
cryptos["Cluster2"] = cryptos["Cluster_inicial"].apply(lambda x : 3 if x == 2
↪else 0)
cryptos["Cluster3"] = cryptos["Cluster_inicial"].apply(lambda x : 2 if x == 3
↪else 0)
cryptos["Cluster"] = cryptos["Cluster0"] + cryptos["Cluster1"] +
↪cryptos["Cluster2"] + cryptos["Cluster3"]
cryptos.drop(["Cluster_inicial", "Cluster0", "Cluster1", "Cluster2",
↪"Cluster3"], axis = 1, inplace = True)
cryptos
```

```
[14]:
```

	Date	Symbol	Close	Marketcap	Volatilidad	Year	Cluster
0	2020-10-05	AAVE	53.219243	8.912813e+07	0.000000	2020	1
1	2020-10-06	AAVE	42.401599	7.101144e+07	0.450850	2020	0
2	2020-10-07	AAVE	40.083976	6.713004e+07	0.233792	2020	0
3	2020-10-08	AAVE	43.764463	2.202651e+08	0.303017	2020	0
4	2020-10-09	AAVE	46.817744	2.356322e+08	0.264133	2020	0
...
2759	2021-02-23	XRP	0.473563	2.150165e+10	0.414389	2021	0
2760	2021-02-24	XRP	0.471832	2.142305e+10	0.060460	2021	1
2761	2021-02-25	XRP	0.434524	1.972912e+10	0.281195	2021	0
2762	2021-02-26	XRP	0.427900	1.942839e+10	0.123462	2021	1
2763	2021-02-27	XRP	0.437809	1.987829e+10	0.152174	2021	1

[34115 rows x 7 columns]

Análisis anual

```
[15]: years = pd.Series(cryptos.Year.unique()).sort_values()

for year in years:
    print(year)
    print(cryptos[cryptos["Year"] == year].Cluster.value_counts(normalize =
↪True))
```

2013

1 0.579666

0 0.420334

Name: Cluster, dtype: float64

2014

1 0.64118

0 0.35882

Name: Cluster, dtype: float64

2015

1 0.728552

0 0.271448

Name: Cluster, dtype: float64

2016

1 0.781421

0 0.218579

Name: Cluster, dtype: float64

2017

1 0.547700

0 0.432203

3 0.020097

Name: Cluster, dtype: float64

2018

1 0.554699

0 0.378228

3 0.067073

Name: Cluster, dtype: float64

2019

1 0.735509

0 0.224532

3 0.039959

Name: Cluster, dtype: float64

2020

1 0.684029

0 0.267594

3 0.046918

2 0.001458

Name: Cluster, dtype: float64

2021

1 0.465517

0 0.449025

```
2    0.043478
3    0.041979
Name: Cluster, dtype: float64
```

Como se ve, a lo largo de los años hay una transición desde clusters inferiores a superiores. Se entiende que los clustes inferiores no desaparecen porque van surgiendo nuevas criptomonedas

Análisis de cada criptomoneda

```
[16]: symbols = pd.Series(cryptos.Symbol.unique())

for symbol in symbols:
    print(symbol)
    print(cryptos[cryptos.Symbol == symbol].Cluster.value_counts(normalize =
↪ True))
```

AAVE

```
0    0.657534
1    0.342466
Name: Cluster, dtype: float64
```

BNB

```
1    0.644326
0    0.355674
Name: Cluster, dtype: float64
```

BTC

```
1    0.494060
3    0.359189
0    0.122642
2    0.024109
Name: Cluster, dtype: float64
```

ADA

```
1    0.600803
0    0.399197
Name: Cluster, dtype: float64
```

LINK

```
1    0.526274
0    0.473726
Name: Cluster, dtype: float64
```

ATOM

```
1    0.592179
0    0.407821
Name: Cluster, dtype: float64
```

CRO

```
1    0.69603
0    0.30397
Name: Cluster, dtype: float64
```

DOGE

```
1    0.692512
0    0.307488
```

```

Name: Cluster, dtype: float64
EOS
1    0.632012
0    0.367988
Name: Cluster, dtype: float64
ETH
1    0.633678
0    0.315116
3    0.051206
Name: Cluster, dtype: float64
MIOTA
1    0.586716
0    0.413284
Name: Cluster, dtype: float64
LTC
1    0.707198
0    0.292802
Name: Cluster, dtype: float64
XMR
1    0.602103
0    0.397897
Name: Cluster, dtype: float64
XEM
1    0.592404
0    0.407596
Name: Cluster, dtype: float64
DOT
1    0.528796
0    0.471204
Name: Cluster, dtype: float64
SOL
0    0.588235
1    0.411765
Name: Cluster, dtype: float64
XLM
1    0.632193
0    0.367807
Name: Cluster, dtype: float64
USDT
1    0.996802
0    0.003198
Name: Cluster, dtype: float64
TRX
1    0.608076
0    0.391924
Name: Cluster, dtype: float64
UNI
0    0.650307

```

```

1    0.349693
Name: Cluster, dtype: float64
USDC
1    0.998855
0    0.001145
Name: Cluster, dtype: float64
WBTC
1    0.806324
0    0.193676
Name: Cluster, dtype: float64
XRP
1    0.697902
0    0.299204
3    0.002894
Name: Cluster, dtype: float64

```

Como se ve, las altcoins más recientes o derivadas de blockhains principales pertenecen al cluster 0, las altcoins mejor asentadas quedan en el cluster 1 y las criptomonedas con diferentes blockhains llegan al cluster 2 (Ethereum, Ripple), mientras que solo Bitcoin llega al 2do y 3er cluster.

Análisis de cada moneda en 2021

```

[17]: for symbol in symbols:
        print(symbol)
        crypto_symbol = cryptos[cryptos.Symbol == symbol]
        print(crypto_symbol[crypto_symbol.Year == 2021].Cluster.
        ↪value_counts(normalize = True))

```

```

AAVE
0    0.655172
1    0.344828
Name: Cluster, dtype: float64
BNB
0    0.534483
1    0.465517
Name: Cluster, dtype: float64
BTC
2    1.0
Name: Cluster, dtype: float64
ADA
0    0.517241
1    0.482759
Name: Cluster, dtype: float64
LINK
0    0.62069
1    0.37931
Name: Cluster, dtype: float64
ATOM
0    0.603448

```

```

1      0.396552
Name: Cluster, dtype: float64
CRO
1      0.534483
0      0.465517
Name: Cluster, dtype: float64
DOGE
0      0.637931
1      0.362069
Name: Cluster, dtype: float64
EOS
1      0.551724
0      0.448276
Name: Cluster, dtype: float64
ETH
3      0.965517
1      0.017241
0      0.017241
Name: Cluster, dtype: float64
MIOTA
1      0.5
0      0.5
Name: Cluster, dtype: float64
LTC
1      0.534483
0      0.465517
Name: Cluster, dtype: float64
XMR
1      0.568966
0      0.431034
Name: Cluster, dtype: float64
XEM
0      0.5
1      0.5
Name: Cluster, dtype: float64
DOT
0      0.62069
1      0.37931
Name: Cluster, dtype: float64
SOL
0      0.655172
1      0.344828
Name: Cluster, dtype: float64
XLM
0      0.568966
1      0.431034
Name: Cluster, dtype: float64
USDT

```

```

1      1.0
Name: Cluster, dtype: float64
TRX
1      0.534483
0      0.465517
Name: Cluster, dtype: float64
UNI
0      0.655172
1      0.344828
Name: Cluster, dtype: float64
USDC
1      1.0
Name: Cluster, dtype: float64
WBTC
1      0.603448
0      0.396552
Name: Cluster, dtype: float64
XRP
0      0.568966
1      0.431034
Name: Cluster, dtype: float64

```

Este resultado refuerza lo concluido anteriormente: BTC ya se asentó en el cluster 3 por su larga historia, ETH se asentó en el cluster 2 por ser la segunda blockchain en ser creada (el resto derivan de BTC), mientras que las altcoins varían entre los primeros dos clusters según su historia.

3 3) Visualización

Elección de criptomonedas Se elegirán 4 criptomonedas para analizar. Cada una perteneció con mayor proporción de días del año 2021 al cluster que ejemplificará:

```

[18]: doge_days_year = cryptos[(cryptos.Year == 2021) & (cryptos.Symbol == "DOGE")].
      ↪Cluster.value_counts(normalize = True).max() * 100
ltc_days_year = cryptos[(cryptos.Year == 2021) & (cryptos.Symbol == "LTC")].
      ↪Cluster.value_counts(normalize = True).max() * 100
eth_days_year = cryptos[(cryptos.Year == 2021) & (cryptos.Symbol == "ETH")].
      ↪Cluster.value_counts(normalize = True).max() * 100
btc_days_year = cryptos[(cryptos.Year == 2021) & (cryptos.Symbol == "BTC")].
      ↪Cluster.value_counts(normalize = True).max() * 100

print("Cluster 0: DOGE (", round(doge_days_year), "% de los días del año )")
print("Cluster 1: LTC (", round(ltc_days_year), "% de los días del año )")
print("Cluster 2: ETH (", round(eth_days_year), "% de los días del año )")
print("Cluster 3: BTC (", round(btc_days_year), "% de los días del año )")

```

```

Cluster 0: DOGE ( 64 % de los días del año )
Cluster 1: LTC ( 53 % de los días del año )
Cluster 2: ETH ( 97 % de los días del año )

```

Cluster 3: BTC (100 % de los días del año)

Boxplots para visualizar la tendencia anual y la estacionalidad mensual El análisis es individual por cada moneda, así que no se unifican las escalas: traería problemas de visualización en las monedas de menor valor y aportaría poco al análisis

```
[19]: doge = pd.DataFrame(cryptos[cryptos.Symbol == "DOGE"])
doge['Month'] = [d.strftime('%b') for d in doge.Date]
years_doge = doge['Year'].unique()

ltc = cryptos[cryptos.Symbol == "LTC"]
ltc['Month'] = [d.strftime('%b') for d in ltc.Date]
years_ltc = ltc['Year'].unique()

eth = cryptos[cryptos.Symbol == "ETH"]
eth['Month'] = [d.strftime('%b') for d in eth.Date]
years_eth = eth['Year'].unique()

btc = cryptos[cryptos.Symbol == "BTC"]
btc['Month'] = [d.strftime('%b') for d in btc.Date]
years_btc = btc['Year'].unique()

[20]: fig, axes = plt.subplots(4, 2, figsize = (20,20), dpi = 80)

box = sns.boxplot(x='Year', y='Close', data = doge, ax = axes[0, 0])
axes[0, 0].xaxis.set_label_position('top')
axes[0, 0].set_xlabel('DOGE', fontsize= 14)
axes[0, 0].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

sns.boxplot(x='Month', y='Close', data = doge.loc[~doge.Year.isin([2013,
↪2021]), :], ax = axes[0, 1], palette='Set3')
axes[0, 1].xaxis.set_label_position('top')
axes[0, 1].set_xlabel('DOGE', fontsize= 14)
axes[0, 1].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

sns.boxplot(x='Year', y='Close', data = ltc, ax = axes[1, 0])
axes[1, 0].xaxis.set_label_position('top')
axes[1, 0].set_xlabel('LTC', fontsize= 14)
axes[1, 0].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

sns.boxplot(x='Month', y='Close', data = ltc.loc[~ltc.Year.isin([2013,
↪2021]), :], ax = axes[1, 1], palette='Set3')
axes[1, 1].xaxis.set_label_position('top')
axes[1, 1].set_xlabel('LTC', fontsize= 14)
axes[1, 1].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

sns.boxplot(x='Year', y='Close', data = eth, ax = axes[2, 0])
```



```

axes[2, 0].xaxis.set_label_position('top')
axes[2, 0].set_xlabel('ETH', fontsize= 14)
axes[2, 0].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

sns.boxplot(x='Month', y='Close', data = eth.loc[~eth.Year.isin([2013,
    ↪2021]), :], ax = axes[2, 1], palette='Set3',
            order = ['Jan', 'Feb', 'Mar', 'Apr', 'May', 'Jun', 'Jul', 'Aug',
    ↪'Sep', 'Oct', 'Nov', 'Dec'])
axes[2, 1].xaxis.set_label_position('top')
axes[2, 1].set_xlabel('ETH', fontsize= 14)
axes[2, 1].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

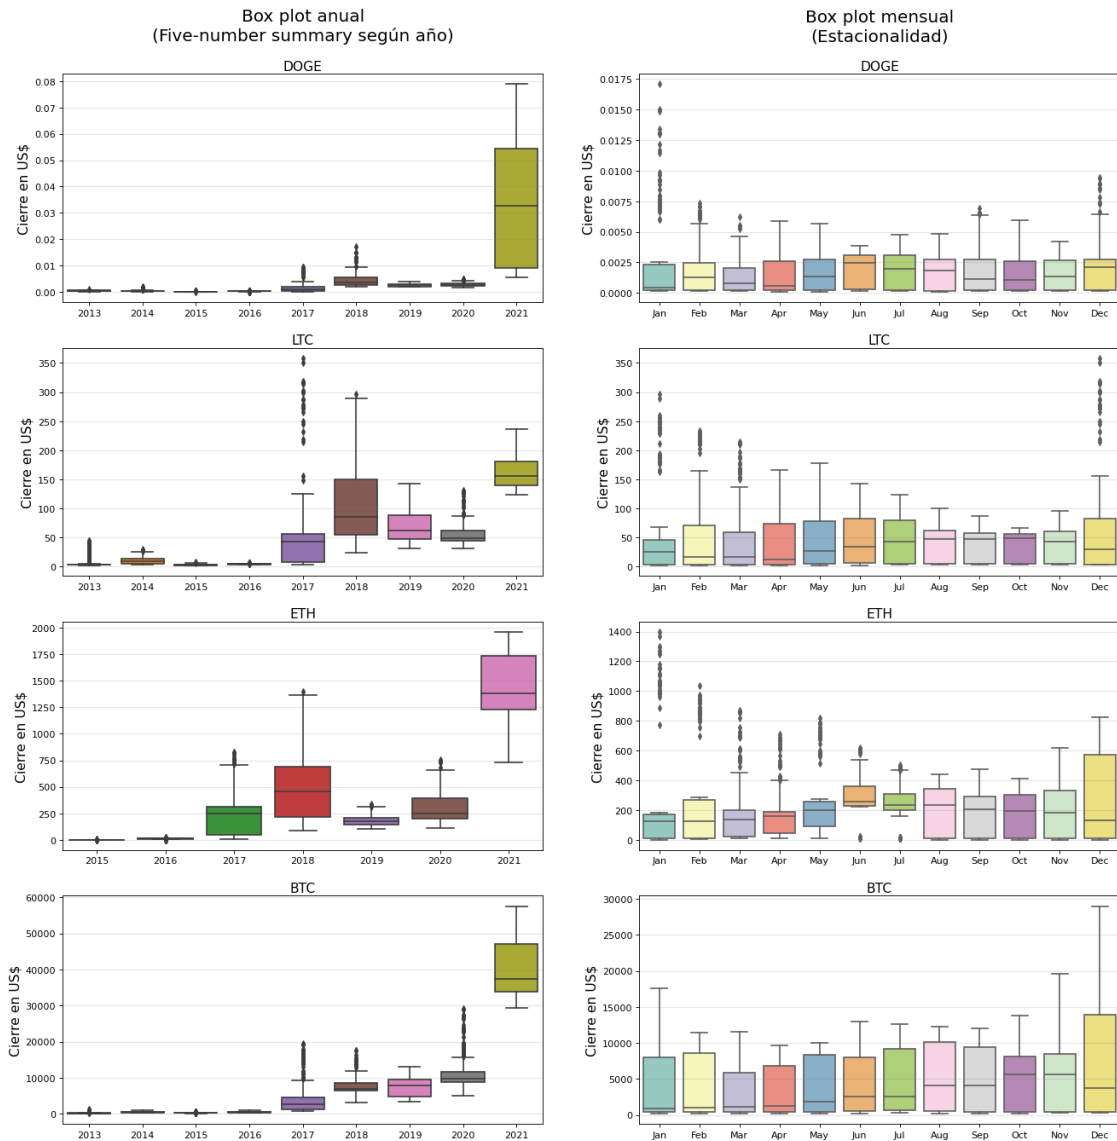
sns.boxplot(x='Year', y='Close', data = btc, ax = axes[3, 0])
axes[3, 0].xaxis.set_label_position('top')
axes[3, 0].set_xlabel('BTC', fontsize= 14)
axes[3, 0].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

sns.boxplot(x='Month', y='Close', data = btc.loc[~btc.Year.isin([2013,
    ↪2021]), :], ax = axes[3, 1], palette='Set3')
axes[3, 1].xaxis.set_label_position('top')
axes[3, 1].set_xlabel('BTC', fontsize= 14)
axes[3, 1].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

#Setemos los títulos:
axes[0, 0].set_title('Box plot anual\n(Five-number summary según año)',
    ↪fontsize = 18, pad = 35);
axes[0, 1].set_title('Box plot mensual\n(Estacionalidad)', fontsize = 18, pad =
    ↪35);
for ax in axes.flat:
    ax.set_ylabel('Cierre en US$', fontsize=14, rotation='vertical');

plt.savefig('Box plots.png')

```



- Al analizar la tendencia, se puede observar que es claramente alcista a lo largo de la corta historia
- Al analizar la estacionalidad, se pueden observar algunos puntos:
 - 1) Hay muy pocos bigotes inferiores debido a la naturaleza alcista de la tendencia.
 - 2) Un cierto aumento en los valores de fin y principio de año (dentro del rango intercuartil en BTC, mediante outliers en ETH, LTC y DOGE).
 - 3) Una diferente volatilidad entre los distintos clusters: DOGE tiene cuerpo del boxplot menor a LTC, quien a su vez tiene menor cuerpo de boxplot que ETH, e igualmente con BTC. A su vez, la relación de tamaño entre bigotes y cuerpo son directamente proporcionales a la volatilidad: DOGE, el más volátil, tiene bigotes mucho más grandes proporcionalmente al cuerpo, en comparación a las monedas menos volátiles. Esto se da, nuevamente, de manera

gradual.

- 4) La enorme diferencia en Volatilidad y en Marketcap de BTC, el único en el cluster 3, podría explicar por qué no tuvo ningún outlier.

Plots para visualizar el valor de cierre y la volatilidad a lo largo de los años

```
[21]: fig2, axes2 = plt.subplots(4, 2, figsize = (20,20), dpi = 80)
plt.subplots_adjust(hspace=0.5)

axes2[0, 0].plot(doge["Date"], doge["Close"], color='g')
axes2[0, 0].xaxis.set_label_position('top')
axes2[0, 0].set_xlabel('DOGE', fontsize= 14)
axes2[0, 0].set_ylabel('Cierre en US$', fontsize=14, rotation='vertical')
axes2[0, 0].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

axes2[0, 1].plot(doge["Date"], doge["Volatilidad"], color='g')
axes2[0, 1].xaxis.set_label_position('top')
axes2[0, 1].set_xlabel('DOGE', fontsize= 14)
axes2[0, 1].set_ylabel('√ de volatilidad porcentual', fontsize=14,
    ↪rotation='vertical')
axes2[0, 1].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

axes2[1, 0].plot(ltc["Date"], ltc["Close"], color='g')
axes2[1, 0].xaxis.set_label_position('top')
axes2[1, 0].set_xlabel('LTC', fontsize= 14)
axes2[1, 0].set_ylabel('Cierre en US$', fontsize=14, rotation='vertical')
axes2[1, 0].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

axes2[1, 1].plot(ltc["Date"], ltc["Volatilidad"], color='g')
axes2[1, 1].xaxis.set_label_position('top')
axes2[1, 1].set_xlabel('LTC', fontsize= 14)
axes2[1, 1].set_ylabel('√ de volatilidad porcentual', fontsize=14,
    ↪rotation='vertical')
axes2[1, 1].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

axes2[2, 0].plot(eth["Date"], eth["Close"], color='g')
axes2[2, 0].xaxis.set_label_position('top')
axes2[2, 0].set_xlabel('ETH', fontsize= 14)
axes2[2, 0].set_ylabel('Cierre en US$', fontsize=14, rotation='vertical')
axes2[2, 0].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

axes2[2, 1].plot(eth["Date"], eth["Volatilidad"], color='g')
axes2[2, 1].xaxis.set_label_position('top')
axes2[2, 1].set_xlabel('ETH', fontsize= 14)
axes2[2, 1].set_ylabel('√ de volatilidad porcentual', fontsize=14,
    ↪rotation='vertical')
```

```

axes2[2, 1].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

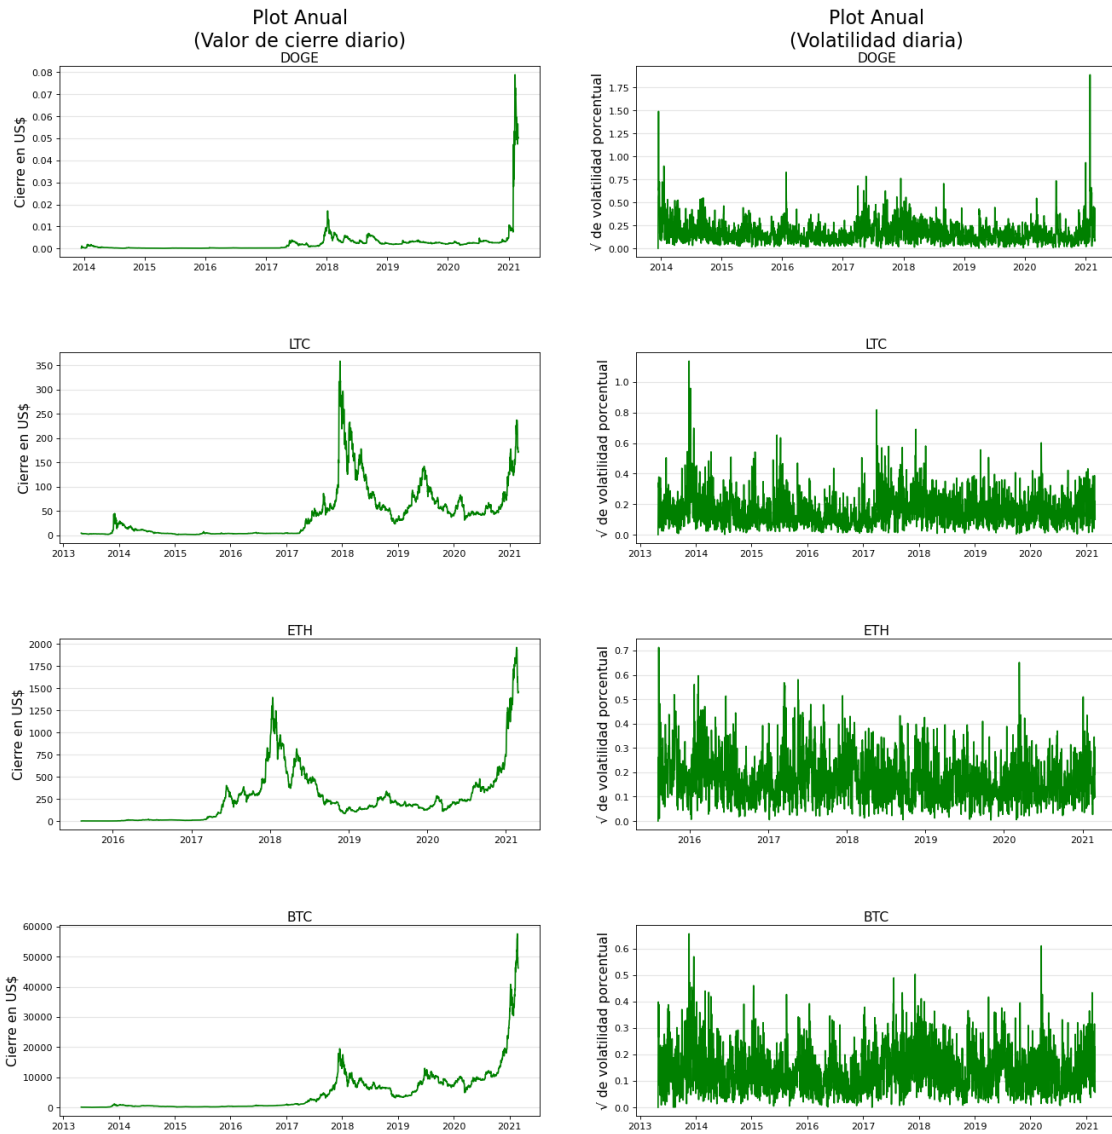
axes2[3, 0].plot(btc["Date"], btc["Close"], color='g')
axes2[3, 0].xaxis.set_label_position('top')
axes2[3, 0].set_xlabel('BTC', fontsize= 14)
axes2[3, 0].set_ylabel('Cierre en US$', fontsize=14, rotation='vertical')
axes2[3, 0].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

axes2[3, 1].plot(btc["Date"], btc["Volatilidad"], color='g')
axes2[3, 1].xaxis.set_label_position('top')
axes2[3, 1].set_xlabel('BTC', fontsize= 14)
axes2[3, 1].set_ylabel('√ de volatilidad porcentual', fontsize=14,
    ↪rotation='vertical')
axes2[3, 1].grid(which='major', axis='y', color='gray', lw=1, alpha=0.2)

#Seteamos los títulos:
axes2[0, 0].set_title('Plot Anual\n(Valor de cierre diario)', fontsize=20);
axes2[0, 1].set_title('Plot Anual\n(Volatilidad diaria)', fontsize=20);

plt.savefig('Plots anuales.png')

```



Se realizará en otra notebook un análisis más exhaustivo de series de tiempo basadas en BTC.